

דו"ח פרויקט מבוא ללמידת מכונה



מגישים

איליה מורגנוב - 206361412

יגל אלפסי - 208788000

איליה מורגנוב - 206361412

עידן שכטר - 209793553

על הדוח להסביר את כלל השלבים אשר ננקטו במהלך ניתוח הנתונים. נדרש הסבר מפורט של הרציונל מאחורי בחירת כל אחד מהשיטות שצוינו בכל שלבי הפרויקט, של ההיפר פרמטרים אשר נבחרו ותוצאות המודלים השונים

תקציר מנהלים

- קובץ ה-Train הינו קובץ בגודל (20x13450) - המכיל 13450 שורות של דגימות ו 20 משתנים, עמודות, לכל דגימה.
- המשתנים הינם ממגוון סוגים - מספריים, טקסט, קטגוריאליים.
- תחילה, ביצענו מספר שיטות ניתוח בסיסי וויזואליזציה שאנו מכירים מהקורס ומקורסים קודמים, כדוגמת טווח ערכי המשתנים המספריים, מספר ערכים ייחודיים, היסטוגרמה לכל עמודה ועוד, זאת על מנת לנסות ולענות על השאלות הבאות:
 - האם יש ערכים חריגים/מיוחדים/או חסרי משמעות?
 - איך כל משתנה מתפלג/"מתנהג"? (מספריים - התפלגות, קטגוריאליים - מספר הקטגוריות וחלוקתן במידע)
 - האם ישנם קשרים בין המשתנים השונים, השוואת משתנה אם אחר, אם כן מהו הקשר?
- (באמצעות SCATTER PLOTS, HEATMAP)
- לאחר קבלת תמונה כללית של המידע שברשותנו ניגשנו למלאכת הניקוי וסידור המידע - טיפול בערכים NULL וקבענו כללי החלטה לטיפול במחסור במידע ובפרט בטיפול בשורות בהם היה קיים מחסור במרבית העמודות (כלומר שורה שכמעט כולה NULL).
- לטובת כך, בנינו פונקציית השלמת ערכים חסרים על ידי שימוש ב KNN והמרת קטגוריות למספרים כדי לטפל גם בהם תוך התחשבות בחוסר האורדינליות של המעבר לייצוג מספרי ("קבוצה 4 לא טובה מקבוצה 5 או להפך").
- בנוסף טיפלנו בערכים החריגים, זיהנו אותם באמצעות שימוש בהיסטוגרמות BOX PLOT ובחלק מהמשתנים הורדנו אותנו ובחלק שבהם הם היו רבים השארנו אותם תוך הפרדה שלהם מהמידע המקורי כדי למנוע רעש מיותר במודלים בהמשך.
- בסיום ניקוי המידע וזיהוי החריגים, ביצענו OHE למשתנים הקטגוריאליים, במהלך תהליך זה גם צמצנו עמודות אשר שאר העמודות ידעו להסביר אותן כמשלים.

- בשלב האחרון של הטיפול במידע, אשר מתחבר באופן טבעי עם השלב הבא, של הפעלת המודלים, ו"לב" הפרוייקט - ביצענו במספר דרכים (IF, HEATMAP, RF, PCA, Logistic Regression וגם סידור ידני) Feature importance.
- בסיום תהליך זה הקובץ שלנו מכיל 12366 שורות עם 30 עמודות, כלומר "איבדנו" 1084 דגימות שהן כ-8% מהדגימות, קיבלנו יותר עמודות למרות הניקוי מאחר שכעת עמודות הקטגוראליות הן OHE.
- בשלב זה עברנו להרצת המודלים השונים ו"משחק" עם ה HP כדי לטייב את הדיוק (AUC) של המודלים, באמצעות Grid Search, אשר השתמשנו כמדד להשוואת המודלים, בהרצת המודלים השתמשנו בהנחות של זמן ריצה קצר יחסית ושימוש בכח החישוב של המחשב האישי שלנו - הנחות וכח חישוב אשר הגבילו את יכולת האקספולרציה שלנו ואת היכולת שלנו לטייב את המודל יותר ממה שהצלחנו.
- בהרצת המודלים מצאנו כי לבעיית הסיווג בה אנו מתעסקים מודל ה RF הוא המדויק ביותר.
- לסיום, הרצנו את הפרדיקציה על נתוני המבחן שלנו כאשר המודל המאומן היה סט האימון כולו עם ההיפר-פרמטרים הכי טובים אשר קיבלנו מהמודל שבחרנו. במהלך העבודה 3 השלבים המרכזיים היו - אקספולרציה של המידע, עיבוד מקדים, המודלים לחיזוי.
- 3 השלבים עונים על השאלות - מה המידע שיש לי? מה אני צריך מהמידע שיש לי? איך אני יכול להתשמש במידע הרלוונטי לסיווג מידע חדש? פסקה קצרה המסכמת את הפרוייקט)
- קובץ ה Train- הינו קובץ בגודל (20x13450) - המכיל 13450 שורות של דגימות ו-20 משתנים (עמודות) לכל דגימה, כאשר ישנם מגוון סוגי משתנים - מספריים, טקסט וקטגוריאלים.
- בחלק הראשון של חקירת הנתונים, ביצענו מספר שיטות ניתוח בסיסיים וויזואליזציות כדוגמת טווח ערכי המשתנים המספריים, מספר ערכים ייחודיים, היסטוגרמות ועוד. כל זאת על מנת לנסות ולענות על השאלות הבאות:
- ⊖ האם יש ערכים חריגים/ מיוחדים/ חסרי משמעות?
- ⊖ איך כל משתנה מתפלג - משתנה נומרי מבחינת התפלגות ומשתנה קטגוריאלי מכיוון מספר הקטגוריות שלו והחלוקה של הקטגוריות בקובץ.
- ⊖ האם ישנם קשרים בין המשתנים השונים בכך שמייצרים השוואות בין המשתנים השונים, אם כן מהו סוג הקשר? אשר נעשה באמצעות Scatter plots, Heatmap.

בחלק השני, לאחר קבלת תמונה כללית של המידע שברשותנו ניגשנו למלאכת הניקוי וסידור המידע: לצורך הטיפול בערכים החסרים ביצענו מספר פעולות וקבענו כללי החלטה שונים ובניהם הורדת תצפיות אשר היה להם לפחות 3 ערכי משתני מסבירים חסרים. כמו כן, בנינו פונקציות עזר לטובת השלמת ערכים חסרים על ידי שימוש ב-KNN והמרת קטגוריות למספרים כדי לטפל גם בהם תוך התחשבות בחוסר האורדינליות של הקטגוריות בהמרה אשר ביצענו.

בנוסף טיפלנו בערכים החריגים, זיהנו אותם באמצעות שימוש ב-Box Plot והורדנו את מה שגילינו בשיטות שונות עם שימוש במידע המקורי בכדי למנוע מצב של הורדת יותר מסט האימון.

בסיום ניקוי המידע וזיהוי החריגים, ביצענו OHE למשתנים הקטגוריאליים, במהלך תהליך זה גם צמצנו עמודות אשר שאר העמודות ידעו להסבירן בצורה משלימה.

לאחר מכן ביצענו Scaling לנתונים וביצענו של הורדת מימד ו-Feature importance באמצעות שילוב של תהליכי PCA, Isolation forest, Random forest.

בסיום תהליך זה הקובץ שלנו מכיל 12366 שורות עם 30 עמודות, כלומר סה"כ הורדנו 1084 דגימות אשר מהוות כ-8% מסט האימון וקיבלנו יותר עמודות מהמקור בשל תהליך של ביצוע OHE על העמודות הקטגוריאליות בתהליך זה.

בחלק השלישי, רצנו מודלים שונים וכן ביצענו טיוב להיפר פרמטרים של כל אחד מהמודלים השונים בכדי לטייב את ביצועי המודל מבחינת AUC, אשר שימש כמדד להשוואת המודלים, באמצעות Grid search. בעת ביצוע תהליך זה השתמשנו בהנחות של זמן ריצה קצר יחסית ושימוש בכוח החישוב של המחשב האישי שלנו, אשר הגבילו את יכולת האקספלורציה והיכולת שלנו לטייב את המודל יותר ממה שהצלחנו. בחלק זה של הרצת המודלים השונים מצאנו כי לבעיית הסיווג בה אנו מתעסקים מודל ה-Random Forest, הוא המדויק ביותר. לסיום, הרצנו את הפרדיקציה על נתוני המבחן שלנו כאשר המודל המאומן היה סט האימון כולו עם ההיפר-פרמטרים הכי טובים אשר קיבלנו מהמודל שבחרנו.

שלב 1 - ניתוח הנתונים ואקספלורציה:

תחילה, כפי שהסברנו בתקציר בתחילת הפרוייקט, בעת קבלת קובץ המידע הגולמי, חיפשנו מענה לשאלות בסיסיות על הנתונים:-

כיצד הם מתפלגים? האם הם קורלטיביים זה עם זה? האם יש התנהגות של משתנים שנראית חריגה או בעלת דפוס כלשהו? האם הנתונים באותו קנה מידה או שנדרשת טרנספורמציה?

כל זאת בכדיזאת על מנת לקבל ידע מקדים ולהבין אם יש צורך לבצע מניפולציות מסוימות על הנתונים בשלב עיבוד המידע. (שלב 2).
ישנן מספר גישות/שיטות לאקספלורציה מאחר וזהו תחום פתוח.
אנחנו פעלנו כלהלן.

ראשית, בכדי להבין את הנתונים בחנו את מספר השורות והעמודות הקיימות לטובת הבנת גודל סט האימון וכן את סוגי העמודות השונים (מספרי/קטגוריאלי/קטגוריאלי אורדינלי וכו') בכדי להבין כיצד עלינו להתייחס ולעבוד ביחס לכל עמודה בנפרד. כמו כן, ניתחנו נתונים סטטיסטיים של העמודות השונות, כמות הערכים החסרים והייחודיים בכל עמודה. לאחר מכן, לטובת הבנה חזותית ביצענו ויזואליזציות שונות לסוגי הנתונים המקוריים שהיו קיימים (ראה נספח #). תחילה, לשם הבנה לגבי העמודות הנומריות יצרנו היסטוגרמות, ולגבי העמודות הקטגוריאליות יצרנו תרשים עוגה לקטגוריות השונות במשתנה 'job type' וכן תרשים עמודות לכל העמודות הקטגוריאליות השונות. בנוסף, בדקנו את הקורלציות בין העמודות השונות באמצעות Heatmap והאם יש קורלציה מסוימת של העמודות ביחס למשתנה המשתנה (דמיון ליחס ליניארי/אקספוננציאלי).

שלב 2 - עיבוד מקדים:

שלב זה היה תהליך ארוך וכלל חלקים שונים: כלל חלקים שונים:

2.א) פעולות טקסט על הנתונים: תחילה, שינינו את שם העמודה "day of week" ל-"day of month", שכן זיהינו כי ישנם 31 ערכים ייחודיים לעמודה זו ועל כן שם העמודה מבלבל ואינו מציג כראוי את נתונים. לאחר מכן ביצענו הורדה לתאים-לאותיות קטגוריות באנגלית לצורת הצגה אחידה של עמודות הכוללות טקסט. בנוסף, שמנו לב שבעמודת "Preferred Call Time", יש שקילות בין "eve", "evening" ו-"Evening", וכך גם בין "morning" ל-"Morning", ובין "Night" ל-"Night", ולכן המרנו את כל אחד מהזמנים השקולים הנ"ל לערך יחיד כך שהערכים אחרי הטרנספורמציה הם: 'evening', 'night', 'morning', 'afternoon', nan.

2.ב) התמודדות עם ערכים חסרים: תחילה, הסרנו את עמודת מזהה הלקוח מהנתונים, שכן היו בה ערכים חסרים וסביר להניח כי לעמודה זו אין משמעות בחיזוי ערך המשתנה המוסבר. לאחר מכן, בדקנו מה היחס של הערכים החסרים בכל עמודה ביחס לכמות

הנתונים והחלטנו להוריד בעקבות כך את עמודות "preferred contact method", "previous campaign outcome" שכן היו להם חסרים של מעל 30% מהשורות והנחנו כי השלמת חסרים ברמה זו לא תהיה יעילה שכן לא נצליח לזהות את המגמה האמיתית של הנתונים בצל כך. יתרה על כך, שמנו לב שיש מספר מזערי של רשומות בהן ערכי "current_campaign_contacts" ו-"current_campaign_contacts" **מתבדלים** **שונים** וכי הם זהים בכל שאר הערכים שאינם חסרים בהם **בצורה-בצורה** שניתן להשלים עמודה אחת על ידי השנייה ולהסיר את אחד מהכפילויות, וכך **אנן** עשינו. לאחר מכן, מאחר וכי אין להסתכלות על העמודה "day of month" בתור עמודה נומרית, שכן אין יחס אורדינלי לימים בחודש לטובת ביצוע החיזוי החלטנו להמירה למשתנה קטגוריאלי.

כעת, ביצענו הנחה סבירה על הנתונים כך שמאחר והיו לנו 15 עמודות החלטנו להוריד שורות אשר הכילו לפחות 3 ערכים חסרים שכן השלמה של כמות ערכים חסרים אלו לכל שורה יכולה להיות לא מדויקת וכן כמות השורות אשר ירדו בעקבות כך (27) מהווה 0.2% מכלל הנתונים אשר לא אמור לפגוע ביכולות החיזוי של המודלים שלנו בהמשך. **לצורך השלמת הערכים החסרים החלטנו להשתמש ב - KNN Imputer, אנן-בצל** **כךמאחר שהמודל-ש-אינו עובד בצורה טובה עם ערכים חסרים ביצענו תהליך מקדים אשר-כלל** **....(פונקציות scale, label encoder, decoder לעמודות הקטגוראיות והשלמת ערכים חסרים בעמודות מספריות (k=5) וקטגוראיות (k=1) באמצעות KNN.** **לאחר מכן, היא מבצעת שחזור המידע המקוד למצב המקורי.)**

2.ג) טיפול בערכים חריגים: לפי הויזואליזציות Boxplots שיצרנו, הבנו שעלינו לבצע הסרת חריגים משמעותית וחכמה בחלק מהעמודות-
 _השיטה העיקרית בה החלטנו להסיר חריגים היא באמצעות IQR, **הסרת-חריגים** כך שכל תצפית שלא בטווח הבין רבעוני: $[Q1 - 1.5IQR, Q3 + 1.5IQR]$ תיחשב לחריגה ולכן תימחק. שיטה זו הפעלנו על העמודות אשר מתפלגות נורמלי (**ZSCORE??**) - **המשתנים המסבירים C & D נורמליים - C עם תוחלת סביב 5, D עם תוחלת סביב 100** בנוסף, המשתנים: "previous campaign contacts", "B" ו-"current campaign contacts" עם זנב ימני קיצוני, כלומר מתפלגות בצורה של זנב ימני ולכן החלטנו להוריד ערכים **חריגים בכך ש....**
 יתרה על כך, העמודה של "Age" החלטנו שלא להסיר אף חריג שכן מאוד ייתכן כי זו ההתפלגות האמיתית באוכלוסייה ועל כן זו תהיה טעות להסירם ויכולה לפגוע ביכולות החיזוי של המודל אשר נפעיל.

סה"כ מצאנו כי ישנם 831 תצפיות עם ערכים חריגים שאותם הורדנו ועל כן בשלב זה נשארו עם 12619 תצפיות.

נשים לב כי באופן יחסי לא ירדו המון ערכים חריגים אך מבחינת הנתונים שכן נשארו הם הפכו להיות יותר אינפורמטיביים

2.2.)

OHE - One Hot Encoding: לאחר הסרת הערכים החריגים, החלטנו לבצע OHE לעמודות הקטגוריאליות שלנו מכיוון שמודלים של למידת מכונה לא יכולים להתמודד עם נתונים קטגוריאלים ושיטה זו על אף שמגדילה את מימד הבעיה, תהליך זה הכרחי לטובת המודלים שנפעיל בהמשך.

2.2) נרמול: כדי שהנתונים שלנו יהיו כולם באותו קנה מידה למניעת משתנה "שמושך" בגלל ערכים קטנים/גדולים מאוד ~~פי שנהג~~, בחרנו לבצע נרמול אחרי ביצוע OHE, על כלל העמודות באמצעות MinMax, כך כל עמודה קטגוריאלית אשר המרנו ~~טרם-לפני~~ ל-0 ו-1 ישמרו על בינאריות זו, ושאר העמודות הנומריות שנותרו ינורמלו כך שהמקסימלי מבניהם בכל עמודה יהיה 1 והמינימלי מבניהם 0 וכל השאר הערכים בעמודה ~~יפלו-יהיו~~ בטווח זה.

2.2) בחירת המסבירים - Feature Selection/Dimensionality Reduction

תחילה, מאחר וביצענו OHE על העמודות הנומריות בצורה בינארית, מבחינת כל קטגוריה אשר המרנו ניתן להסיר את אחד מהעמודות בצורה שרירותית שכן ניתן להסביר את העמודה האחרונה בכל קטגוריה באמצעות שימוש בשאר העמודות הבינאריות של קטגוריה זו. לאחר הסרה זו בדקנו גם באמצעות מדד ה- **VIF** אשר בודק האם משתנה מוסבר אחד יכול להיות מוסבר ע"י האחרים וגילינו כי אין ערכים אשר מוגדרים חריגים ביחס למדד זה לטובת הסרה נוספת של עמודות. לאחר מכן ביצענו שילוב בין **Random Forest** - **PCA**, על מנת לגלות מי המשתנים המסבירים הכי חשובים ושמביאים לכדי ביטוי הכי הרבה מהשונות שבנתונים, החלטנו לזהות בעזרת ה- RF את ה-20 משתנים הכי חשובים אשר הוא מזהה ממה שנותר וכן הרצנו PCA בכך שיהיו לו 15 קומפוננטות, **כמות סבירה ביחס לכמות העמודות**, וביצענו שילוב של מה שזוהה שחשוב מבין שניהם והורדנו את העמודות אשר לא הופיעו באף אחד משתי שיטות אלו ובצורה זו הורדנו משמעותית את המימד של הנתונים לכדי 29 עמודות כאשר במקור לאחר ביצוע תהליך ה- OHE היו 74 עמודות.

חלק 3 - הרצת המודלים:

תחילה, פיצלנו את הנתונים שלנו מסט האימון המקורי, לסט אימון חדש וסט ולידציה (-80% 20%). על סט האימון החדש, ביצענו Stratified K-Fold Cross Validation דרך

Grid search עם $K=5$, שכן זוהי הנחה נוספת אשר הנחנו **מאחר ו..... (שיקולי bias-variance tradeoff / גודל הדאטה)**, שכן K קטן מדי גורר מודל רגיש מידי עם הטייה נמוכה ושונות גבוהה ולמצב של Overfit על הנתונים, ואילו K גבוה מדי פחות רגיש עם הטייה גבוהה ושונות נמוכה ויכול להוביל למצב של Underfit. השתמשנו ב- Grid search לכל מודל, במטרה לבדוק מספר היפר-פרמטרים שונים וכל הקומבינציות האפשריות שלהן אשר ניתן לייצר בכדי לזהות את המודל הכי טוב. נציין, כי תהליך זה עשוי היה להיות ארוך בזמנים ויקר מאוד חישובית, כתלות ביכולת חישוב ומספר הערכים האפשריים אשר אנו מנסים להכניס לכל מודל ולכן ייתכן מאוד כי ישנם היפר-פרמטרים יותר טובים למודלים אשר הרצנו אך מפאת חוסר יכולת **חישוב גדולה** וזמן לעבור על כל ערך וקומבינציית פרמטרים אפשרית זהו התוצאה הכי טובה אשר הגענו אליה לאחר מספר **נשנה** של הרצות על כלל המודלים. בנוסף, עבור כל אחד מהמודלים אשר הרצנו, הדפסנו מה ההיפר פרמטרים הכי טובים שקיבלנו מהסט אשר בדקנו וכן מטריקות רלוונטיות שונות כמו: precision, recall, f1-score, support וכן הדפסנו את עקומת ה- ROC לכל אחד מה-Folds והממוצע שהתקבל. מבחינת ביצועי AUC, אשר מהווה המדד להשוואה בין המודלים, לרוב התוצאה יצאה באזור ה- 0.7 כאשר המודל הכי טוב מבין כלל המודלים אשר הרצנו היה מודל ה-Random Forest עם ערך ממוצע של 0.74 כך שההיפר פרמטרים הכי טובים למודל זה היו:

ל עודד את ההיפר פרמטרים הכי טובים - מה שכרגע הורץ לדעתי השגתי יותר טוב ממש בקטנה אבל עדיין - גם יש עוד עמודה שלא הסרנו בטעות כי התפספס אם רואים לנכון להוסיף עוד מידע כאן בנוגע להרצות מוזמנים

חלק 4 - הערכת ביצועי המודל: בחלק זה בנינו confusion matrix **בצורה מדגמית למודל ה-...**

ממבט קצר על ה-confusion matrix, ניתן לראות כי המודל מסווג ..

חלק 4-5 - ביצוע החיזוי: בחלק זה, לאחר שביצענו את כלל הפעולות השונות על סט האימון והרצת המודלים, ביצענו את אותו תהליך של Pre-processing אשר ביצענו על

סט האימון, למעט הורדת חריגים שכן אסור להוריד שורות מסט המבחן. אך נציין כי על מאחר וייתכן מאוד שגם בסט המבחן ישנם ערכים חריגים החלטנו על מנת להיטיב את יכולת החיזוי, שבכל עמודה נומרית אמיתית שישנה חתכנו את ערכי העמודה להיות בין הערך המקסימלי והמינימלי אשר היה בעמודה בסט האימון בהתאמה וכך לא נצטרך לבצע חיזוי על ערך אשר לא נלמד בסט האימון ולקבל תוצאת חיזוי. לאחר מכן אימנו את מודל ה-RF עם ההיפר-פרמטרים הכי טובים שהתקבלו על כל סט האימון המלא וביצענו חיזוי על סט המבחן אשר קיבלנו ויצרנו את הקובץ הסתברויות חיזוי כנדרש.

ההנחות השונות בפרויקט

לאורך ביצוע הפרויקט לקחנו בחשבון מספר הנחות: ~~(לקחת מכל המלל המרובה שכתבתי ללקט את מה שכתוב הנחה וזה ולהוסיף עוד אם פספסתי כמובן)~~

- יש לפרט את ההנחות שנלקחו בכל שלב של הפרויקט. הנחות שלא יפורטו יחשבו כאילו לא נלקחו בחשבון ומצב זה עלול להוביל להורדה בציון.

סיכום מתאר את כלל המודלים והמסקנות שנסקרו במהלך ניתוח הנתונים בגלל כל התהליך שרשמתי למעלה אשר מכסה פחות או יותר הכל לדעתי שווה כאן לכתוב את כל מיני הניסיונות השונים שניסנו אשר מחקנו בסופו של דבר למרות הערה שיש בPDF

- גם אם ניסתם "לפצח" את הבעיה בדרך מסוימת ואין שיפור בתוצאות: אל תסירו את הניסיון מהקוד. רק חשוב שתדגישו שמדובר בניסיון לא מוצלח ואין לו מקום ב work flow-הסופי.

מותר לכל היותר עד חמישה עמודים לא כולל עמוד שער ונספחים

נספחים – ויזואליזציה עם הפניה לקוד ככל העולה על רוחנו